

Практическое занятие №5

Вариант №1

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Определите модуль разницы между средними тратами женщин и мужчин (трата – отрицательное значение `amount`). Выведите ответ в виде вещественного числа, округлённого до двух знаков после запятой, отделив дробную часть точкой в формате "123.45". Создайте новый столбец – `mcc_code+tr_type`, сложив значения из соответствующих столбцов.

Пояснения:

- Если в результате для мужчин получились значения `[-1,-3,-5]`, а для женщин `[-1,-2,-3]`, то модуль разницы между средними арифметическими -3 и -2 будет равен 1.
 - Для вычисления модуля разности точных знаний о том, какой класс относится к мужчинам, а какой – к женщинам, не требуется.
 - Округление не нужно производить отдельно по средним тратам женщин и мужчин, а только в самом конце, когда получите значение модуля разницы трат.
2. Из всех типов транзакций оставьте только траты (отрицательные суммы по столбцу `amount`). Выделите из поля `tr_datetime` относительный день `tr_day` (первое число до точного времени). Измените тип поля `tr_day` на `int`. Выберите из `transactions` все МСС коды, которые встретились в выборке более чем 60000 раз. Сгруппируйте отфильтрованный датафрейм по дню и МСС-коду, получая средние значения суммы `amount`. Отрисуйте зависимость средних сумм (может пригодится метод `unstack()`) по каждому из МСС-кодов по дням. Проверьте верно ли, что 2 из полученных МСС-кодов связаны с финансовыми институтами.

Пояснение: Для того, чтобы выделить всё, что стоит до первого пробела, можно использовать строковые методы для датафрейма - `.str.split()`, например. Либо же реализовывать логику выделения подстроки с помощью метода `apply`.

Вариант №2

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Создайте новый столбец – `mcc_code+tr_type`, сконкатенировав значения из соответствующих столбцов. Для конкатенации значений в столбцах нужно использовать метод `.astype(str)` для серии и складывать соответствующие серии. Оставьте только наблюдения с положительным значением `amount`. Посчитайте средние значения по категориям получившегося столбца `mcc_code+tr_type`, в которых количество наблюдений `>=5` и `<=25`. Выведите ответ в виде вещественного числа, округлённого до 2-х знаков после запятой.
2. По данным полученной таблицы изобразите гистограмму.

Вариант №3

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Создайте новый столбец – `mcc_code+tr_type`, сконкатенировав значения из соответствующих столбцов. Оставьте только наблюдения с отрицательным значением `amount`. Посчитайте дисперсию по категориям получившегося столбца `mcc_code+tr_type`, в которых количество наблюдений ≥ 10 . Определите отношение максимальной дисперсии к минимальной. Выведите ответ в виде вещественного числа, округлённого до ближайшего целого в формате "123456" без дробной части.

Пояснения:

- Для конкатенации значений в столбцах нужно применить `apply` к строкам датафрейма, прописывая логику преобразования и конкатенации значений внутри.
- Для одновременного подсчёта количества наблюдений и дисперсии по категориям можно воспользоваться функцией `.agg()`.

2. По данным полученной таблицы изобразите составную столбчатую диаграмму на основе нескольких серий.

Вариант №4

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). По всем типам транзакций рассчитайте максимальную сумму прихода на карту (из строго положительных сумм по столбцу `amount`) отдельно для мужчин и женщин (назовите ее "`max_income`"). Оставьте по 6 транзакций для мужчин и для женщин, наибольших среди всех транзакций по полученным значениям "`max_income`". Выделите среди них те, которые не встречаются одновременно у мужчин и у женщин.

Пояснение: если максимальные суммы приходов по каким-то типам были равны [1,2,3,4,5,6,7,8], то 5 максимальных из них: [4,5,6,7,8].

2. По данным полученной таблицы изобразите диаграмму рассеивания.

Вариант №5

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). По всем типам транзакций рассчитайте максимальную сумму прихода на карту (из строго положительных сумм по столбцу `amount`) отдельно для мужчин и женщин (назовите ее `"max_income"`). Оставьте по 5 транзакций для мужчин и для женщин, наименьших среди всех транзакций по полученным значениям `"max_income"`. Выделите среди них те, которые встречаются одновременно и у мужчин, и у женщин.

Пояснение: если максимальные суммы приходов по каким-то типам были равны [1,2,3,4,5,6,7,8], то 5 минимальных из них: [1,2,3,4,5].

2. По данным полученной таблицы изобразите составную горизонтальную столбчатую диаграмму на основе нескольких серий.

Вариант №6

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Выделите из поля `tr_datetime` относительный день `tr_day` (первое число до точного времени). Отфильтруйте строки таким образом, чтобы оставить только те транзакции, у которых в соответствующий относительный день `tr_day` количество уникальных MCC кодов при транзакциях было больше 75 (можно воспользоваться функцией `nunique()`). Сгруппируйте полученный отфильтрованный датафрейм по MCC коду и полу, после чего, проанализировав результат, определите женщины или мужчины относятся к `gender == 0`.

Пояснения:

- Для того, чтобы выделить всё, что стоит до первого пробела, можно использовать строковые методы для датафрейма – `.str.split()`, например. Либо же реализовывать логику выделения подстроки с помощью метода `apply`.
- Понять, какой класс к какому типу транзакций (мужские/женские) относится можно, если поизучать типичные для мужчин/женщин категории и сравнить средние/медианы расходов и/или приходов в них.

2. По данным полученной таблицы изобразите столбчатую диаграмму на основе нескольких серий.

Вариант №7

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Разбейте расходы (отрицательные значения сумм) на 5 бакетов `amount_bucket` равного объёма (с помощью `pd.qcut`), разбив все траты на категории 'Very High', 'High', 'Middle', 'Low', 'Very Low'. Оставшиеся неотрицательные траты отнесите к категории 'Income' (воспользуйтесь функцией `.cat.add_categories('Income')` для того, чтобы добавить новую категорию 'Income' к категориям 'Very High', 'High', 'Middle', 'Low', 'Very Low', а затем заполните пустые значения новой категорией).

Пояснение: в категории Very High должны оказаться максимальные по модулю отрицательные транзакции.

2. Отрисуйте полученные результаты, передав их в функцию `plot_pivot_table`, расположенную ниже.

```
def plot_pivot_table(pivot_table):
    plt.figure(figsize=(9, 11))
    sns.heatmap(pivot_table, cmap="YlGnBu", annot=True,
                fmt='.3g', annot_kws={"size": 14, "fontsize": 14})
    plt.xticks(fontsize=15)
    plt.yticks(rotation=0, fontsize=15)
    plt.xlabel('Bucket', size=18)
    plt.ylabel('Hour', fontsize=18)
    plt.title('Gender analysis per bucket and hour', fontsize=20)
    plt.show()
```

Проверьте действительно ли:

- ночные поступления денег (01-05 часов) в более чем 85% случаев являются мужскими;
- посмотрев на долю мужчин в поступлениях средств (Income), можно сделать вывод, что количество поступлений средств женщинам в целом больше, чем мужчинам.

Вариант №8

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Из всех типов транзакций оставьте только положительные суммы прихода на карту (положительные суммы по столбцу `amount`). Из поля `tr_datetime` выделите час `tr_hour`, в который произошла транзакция, как первые 2 цифры до ":". После этого постройте сводную таблицу, значениями в которой является пол `gender`, индексы – `tr_hour`, столбцы – `amount_bucket`.

Пояснение: для строки "0 10:23:26" час будет равен 10, а для строки "6 07:08:31" – 07. Нужно воспользоваться функциями `str.split()` и `.apply(lambda x: x[0])`.

2. Отрисуйте полученные результаты, передав их в функцию `plot_pivot_table`, расположенную ниже.

```
def plot_pivot_table(pivot_table):  
    plt.figure(figsize=(9, 11))  
    sns.heatmap(pivot_table, cmap="YlGnBu", annot=True,  
                fmt='.3g', annot_kws={"size": 14, "fontsize": 14})  
    plt.xticks(fontsize=15)  
    plt.yticks(rotation=0, fontsize=15)  
    plt.xlabel('Bucket', size=18)  
    plt.ylabel('Hour', fontsize=18)  
    plt.title('Gender analysis per bucket and hour', fontsize=20)  
    plt.show()
```

Проверьте действительно ли:

- самые низкие траты в 3 часа ночи осуществляются в более 70% случаев женщинами;
- существуют особые часы в мелких тратах, когда женщины тратят намного больше мужчин (>80%).

Вариант №9

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Из всех типов транзакций оставьте только отрицательные суммы прихода на карту (отрицательные суммы по столбцу `amount`). Из поля `tr_datetime` выделите час `tr_hour`, в который произошла транзакция, как первые 2 цифры до ":". После этого постройте сводную таблицу, значениями в которой является пол `gender`, индексы – `tr_hour`, столбцы – `amount_bucket`.

Пояснение: для строки "0 10:23:26" час будет равен 10, а для строки "6 07:08:31" – 07. Можно воспользоваться функциями `str.find()` и `.apply(lambda x: x[0])`.

2. Отрисуйте полученные результаты, передав их в функцию `plot_pivot_table`, расположенную ниже.

```
def plot_pivot_table(pivot_table):
    plt.figure(figsize=(9, 11))
    sns.heatmap(pivot_table, cmap="YlGnBu", annot=True,
                fmt='.3g', annot_kws={"size": 14, "fontsize": 14})
    plt.xticks(fontsize=15)
    plt.yticks(rotation=0, fontsize=15)
    plt.xlabel('Bucket', size=18)
    plt.ylabel('Hour', fontsize=18)
    plt.title('Gender analysis per bucket and hour', fontsize=20)
    plt.show()
```

Проверьте действительно ли:

- ночные поступления денег (01-05 часов) в более чем 85% случаев являются мужскими;
- посмотрев на долю мужчин в поступлениях средств (Income), можно сделать вывод, что количество поступлений средств женщинам в целом больше, чем мужчинам.

Вариант №10

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Из всех типов транзакций оставьте только положительные суммы прихода на карту (положительные суммы по столбцу `amount`). Выделите из поля `tr_datetime` относительный день `tr_day` (первое число до точного времени). Измените тип поля `tr_day` на `int`. Выберите из `transactions` все МСС коды, которые встретились в выборке более чем 60000 раз. Сгруппируйте отфильтрованный датафрейм по дню и МСС-коду, получая средние значения суммы `amount`.
2. Далее отрисуйте зависимость средних сумм (может пригодится метод `unstack()`) по каждому из МСС-кодов по дням.

Проверьте действительно ли:

- бакалейные магазины обладают максимальными средними тратами среди выбранных МСС-кодов;
- денежные переводы имеют как минимум 3 явных минимума средних.

Пояснения:

- Для того, чтобы выделить всё, что стоит до первого пробела, можно использовать строковые методы для датафрейма - `.str.split()`, например. Либо же реализовывать логику выделения подстроки с помощью метода `apply`.

Вариант №11

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). По всем типам транзакций рассчитайте максимальную сумму прихода на карту (из строго положительных сумм по столбцу `amount`) отдельно для мужчин и женщин (назовите ее `"max_income"`). Оставьте по 10 транзакций для мужчин и для женщин, наименьших среди всех транзакций по полученным значениям `"max_income"`. Выделите среди них те, которые встречаются одновременно и у мужчин, и у женщин.
2. По данным полученной таблицы изобразите составную круговую диаграмму на основе нескольких серий.

Вариант №12

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Определите модуль разницы между средними тратами женщин и мужчин (трата – отрицательное значение `amount`). Выведите ответ в виде вещественного числа, округлённого одного знака после запятой, отделив дробную часть точкой в формате "123.4". Создайте новый столбец – `mcc_code+tr_type`, сложив значения из соответствующих столбцов.

Пояснения:

- Если в результате для мужчин получились значения `[-1,-3,-5]`, а для женщин `[-1,-2,-3]`, то модуль разницы между средними арифметическими `-3` и `-2` будет равен 1.
 - Для вычисления модуля разности точных знаний о том, какой класс относится к мужчинам, а какой – к женщинам, не требуется.
 - Округление не нужно производить отдельно по средним тратам женщин и мужчин, а только в самом конце, когда получите значение модуля разницы трат.
2. Из всех типов транзакций оставьте только траты (отрицательные суммы по столбцу `amount`). Выделите из поля `tr_datetime` относительный день `tr_day` (первое число до точного времени). Измените тип поля `tr_day` на `int`. Измените тип поля `tr_day` на `int`. Выберите из `transactions` все МСС коды, которые встретились в выборке более чем 55000 раз. Сгруппируйте отфильтрованный датафрейм по дню и МСС-коду, получая средние значения суммы `amount`. Отрисуйте зависимость средних сумм (может пригодится метод `unstack()`) по каждому из МСС-кодов по дням. Проверьте верно ли, что 2 МСС кода, связанные со снятием наличности имеют в целом разные знаки (в одном случае почти везде – траты, в другом – пополнения).

Вариант №13

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Создайте новый столбец – `mcc_code+tr_type`, сконкатенировав значения из соответствующих столбцов. Для конкатенации значений в столбцах нужно использовать метод `.astype(str)` для серии и складывать соответствующие серии. Оставьте только наблюдения с положительным значением `amount`. Посчитайте средние значения по категориям получившегося столбца `mcc_code+tr_type`, в которых количество наблюдений `>=4` и `<=30`. Выведите ответ в виде вещественного числа, округлённого до 3-х знаков после запятой.
2. По данным полученной таблицы изобразите гистограмму в нормированном виде (показывающую дискретизированную плотность, а поверх неё график ядерной оценки плотности).

Вариант №14

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Из всех типов транзакций оставьте только отрицательные суммы прихода на карту (отрицательные суммы по столбцу `amount`). Из поля `tr_datetime` выделите час `tr_hour`, в который произошла транзакция, как первые 2 цифры до ":". После этого постройте сводную таблицу, значениями в которой является пол `gender`, индексы – `tr_hour`, столбцы – `amount_bucket`.

Пояснение: для строки "0 10:23:26" час будет равен 10, а для строки "6 07:08:31" – 07. Можно воспользоваться функциями `str.find()` и `.apply(lambda x: x[:])`.

2. Отрисуйте полученные результаты, передав их в функцию `plot_pivot_table`, расположенную ниже.

```
def plot_pivot_table(pivot_table):
    plt.figure(figsize=(9, 11))
    sns.heatmap(pivot_table, cmap="YlGnBu", annot=True,
                fmt='.3g', annot_kws={"size": 14, "fontsize": 14})
    plt.xticks(fontsize=15)
    plt.yticks(rotation=0, fontsize=15)
    plt.xlabel('Bucket', size=18)
    plt.ylabel('Hour', fontsize=18)
    plt.title('Gender analysis per bucket and hour', fontsize=20)
    plt.show()
```

Проверьте действительно ли:

- ночные поступления денег (01-05 часов) в более чем 85% случаев являются женскими;
- самые низкие траты в 3 часа ночи осуществляются в более 70% случаев женщинами.

Вариант №15

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). По всем типам транзакций рассчитайте максимальную сумму прихода на карту (из строго положительных сумм по столбцу `amount`) отдельно для мужчин и женщин (назовите ее `max_income`). Оставьте по 10 транзакций для мужчин и для женщин, наибольших среди всех транзакций по полученным значениям `max_income`. Выделите среди них те, которые встречаются одновременно у мужчин и у женщин.
2. Визуализируйте на рисунке данные полученной таблицы.

Вариант №16

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Определите какой класс относится к мужчинам, а какой – к женщинам, и вычислите модуль разницы между их средними тратами (трата – отрицательное значение `amount`). Выведите ответ в виде вещественного числа, округлённого до трех знаков после запятой. Создайте новый столбец – `mcc_code+tr_type`, сложив значения из соответствующих столбцов.

Пояснения:

- Понять, какой класс к какому типу транзакций (мужские/женские) относится можно, если поизучать типичные для мужчин/женщин категории и сравнить средние/медианы расходов и/или доходов в них.
 - Если в результате для мужчин получились значения `[-1,-3,-5]`, а для женщин `[-1,-2,-3]`, то модуль разницы между средними арифметическими `-3` и `-2` будет равен 1.
 - Округление не нужно производить отдельно по средним тратам женщин и мужчин, а только в самом конце, когда получите значение модуля разницы трат.
2. Из всех типов транзакций оставьте только траты (отрицательные суммы по столбцу `amount`). Выделите из поля `tr_datetime` относительный день `tr_day` (первое число до точного времени). Измените тип поля `tr_day` на `int`. Выберите из `transactions` все МСС коды, которые встретились в выборке более чем 55000 раз. Сгруппируйте отфильтрованный датафрейм по дню и МСС-коду, получая средние значения суммы `amount`. Отрисуйте зависимость средних сумм (может пригодится метод `unstack()`) по каждому из МСС-кодов по дням. Проверьте верно ли, что денежные переводы имеют как минимум 3 явных минимума средних.

Пояснение: Для того, чтобы выделить всё, что стоит до первого пробела, можно использовать строковые методы для датафрейма - `.str.split()`, например. Либо же реализовывать логику выделения подстроки с помощью метода `apply`.

Вариант №17

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Создайте новый столбец – `mcc_code+tr_type`, сконкатенировав значения из соответствующих столбцов. Для конкатенации значений в столбцах нужно использовать метод `.astype(str)` для серии и складывать соответствующие серии. Оставьте только наблюдения с положительным значением `amount`. Посчитайте средние значения по категориям получившегося столбца `mcc_code+tr_type`, в которых количество наблюдений `>=5` и `<=30`. Выведите ответ в виде вещественного числа, округлённого до 2-х знаков после запятой.
2. По данным полученной таблицы изобразите круговую диаграмму.

Вариант №18

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Создайте новый столбец – `mcc_code+tr_type`, сконкатенировав значения из соответствующих столбцов. Оставьте только наблюдения с отрицательным значением `amount`. Посчитайте дисперсию по категориям получившегося столбца `mcc_code+tr_type`, в которых количество наблюдений ≥ 5 . Определите отношение максимальной дисперсии к минимальной. Выведите ответ в виде вещественного числа, округлённого до ближайшего целого без дробной части.

Пояснения:

- Для конкатенации значений в столбцах нужно применить `apply` к строкам датафрейма, прописывая логику преобразования и конкатенации значений внутри.
 - Для одновременного подсчёта количества наблюдений и дисперсии по категориям можно воспользоваться функцией `.agg()`.
2. По данным полученной таблицы изобразите составную горизонтальную столбчатую диаграмму на основе нескольких серий.

Вариант №19

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Разбейте расходы (отрицательные значения сумм) на 5 бакетов `amount_bucket` равного объёма (с помощью `pd.qcut`), разбив все траты на категории 'Very High', 'High', 'Middle', 'Low', 'Very Low'. Оставшиеся неотрицательные траты отнесите к категории 'Income' (воспользуйтесь функцией `.cat.add_categories('Income')` для того, чтобы добавить новую категорию 'Income' к категориям 'Very High', 'High', 'Middle', 'Low', 'Very Low', а затем заполните пустые значения новой категорией).

Пояснение: в категории `Very High` должны оказаться максимальные по модулю отрицательные транзакции.

2. Отрисуйте полученные результаты, передав их в функцию `plot_pivot_table`, расположенную ниже.

```
def plot_pivot_table(pivot_table):
    plt.figure(figsize=(9, 11))
    sns.heatmap(pivot_table, cmap="YlGnBu", annot=True,
                fmt=".3g", annot_kws={"size": 14, "fontsize": 14})
    plt.xticks(fontsize=15)
    plt.yticks(rotation=0, fontsize=15)
    plt.xlabel('Bucket', size=18)
    plt.ylabel('Hour', fontsize=18)
    plt.title('Gender analysis per bucket and hour', fontsize=20)
    plt.show()
```

Проверьте действительно ли:

- ночные поступления денег (01-05 часов) в более чем 85% случаев являются мужскими;
- существуют особые часы в мелких тратах, когда женщины тратят намного больше мужчин (>80%).

Вариант №20

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). По всем типам транзакций рассчитайте максимальную сумму прихода на карту (из строго положительных сумм по столбцу `amount`) отдельно для мужчин и женщин (назовите ее `"max_income"`). Оставьте по 20 транзакций для мужчин и для женщин, наибольших среди всех транзакций по полученным значениям `"max_income"`. Выделите среди них те, которые встречаются одновременно и у мужчин, и у женщин.

Пояснение: если максимальные суммы приходов по каким-то типам были равны [1,2,3,4,5,6,7,8], то 5 максимальных из них: [4,5,6,7,8].

2. По данным полученной таблицы изобразите гистограмму.

Вариант №21

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Выделите из поля `tr_datetime` относительный день `tr_day` (первое число до точного времени). Отфильтруйте строки таким образом, чтобы оставить только те транзакции, у которых в соответствующий относительный день `tr_day` количество уникальных MCC кодов при транзакциях было больше 70 (можно воспользоваться функцией `nunique()`). Сгруппируйте полученный отфильтрованный датафрейм по MCC коду и полу, после чего, проанализировав результат, определите женщины или мужчины относятся к `gender == 1`.

Пояснения:

- Для того, чтобы выделить всё, что стоит до первого пробела, можно использовать строковые методы для датафрейма – `.str.split()`, например. Либо же реализовывать логику выделения подстроки с помощью метода `apply`.
- Понять, какой класс к какому типу транзакций (мужские/женские) относится можно, если поизучать типичные для мужчин/женщин категории и сравнить средние/медианы расходов и/или приходов в них.

2. По данным полученной таблицы изобразите столбчатую диаграмму на основе нескольких серий.

Вариант №22

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Создайте новый столбец – `mcc_code+tr_type`, сконкатенировав значения из соответствующих столбцов. Для конкатенации значений в столбцах нужно использовать метод `.astype(str)` для серии и складывать соответствующие серии. Оставьте только наблюдения с положительным значением `amount`. Посчитайте средние значения по категориям получившегося столбца `mcc_code+tr_type`, в которых количество наблюдений ≥ 5 и ≤ 35 . Выведите ответ в виде вещественного числа, округлённого до 2-х знаков после запятой.
2. По данным полученной таблицы изобразите график ядерной оценки плотности.

Вариант №23

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Из всех типов транзакций оставьте только положительные суммы прихода на карту (положительные суммы по столбцу `amount`). Из поля `tr_datetime` выделите час `tr_hour`, в который произошла транзакция, как первые 2 цифры до ":". После этого постройте сводную таблицу, значениями в которой является пол `gender`, индексы – `tr_hour`, столбцы – `amount_bucket`.
Пояснение: для строки "0 10:23:26" час будет равен 10, а для строки "6 07:08:31" – 07. Нужно воспользоваться функциями `str.split()` и `.apply(lambda x: x[0])`.
2. Отрисуйте полученные результаты, передав их в функцию `plot_pivot_table`, расположенную ниже.

```
def plot_pivot_table(pivot_table):
    plt.figure(figsize=(9, 11))
    sns.heatmap(pivot_table, cmap="YlGnBu", annot=True,
                fmt='.3g', annot_kws={"size": 14, "fontsize": 14})
    plt.xticks(fontsize=15)
    plt.yticks(rotation=0, fontsize=15)
    plt.xlabel('Bucket', size=18)
    plt.ylabel('Hour', fontsize=18)
    plt.title('Gender analysis per bucket and hour', fontsize=20)
    plt.show()
```

Проверьте действительно ли:

- Посмотрев на долю мужчин в максимальных тратах средств (Very High), можно сделать вывод, что количество высоких трат в каждый возможный час у мужчин больше, чем у женщин;
- Посмотрев на долю мужчин в поступлениях средств (Income), можно сделать вывод, что количество поступлений средств женщинам в целом больше, чем мужчинам.

Вариант №24

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Разбейте расходы (отрицательные значения сумм) на 5 бакетов `amount_bucket` равного объёма (с помощью `pd.qcut`), разбив все траты на категории 'Very High', 'High', 'Middle', 'Low', 'Very Low'. Оставшиеся неотрицательные траты отнесите к категории 'Income' (воспользуйтесь функцией `.cat.add_categories('Income')` для того, чтобы добавить новую категорию 'Income' к категориям 'Very High', 'High', 'Middle', 'Low', 'Very Low', а затем заполните пустые значения новой категорией).

Пояснение: в категории Very High должны оказаться максимальные по модулю отрицательные транзакции.

2. Отрисуйте полученные результаты, передав их в функцию `plot_pivot_table`, расположенную ниже.

```
def plot_pivot_table(pivot_table):
    plt.figure(figsize=(9, 11))
    sns.heatmap(pivot_table, cmap="YlGnBu", annot=True,
                fmt='.3g', annot_kws={"size": 14, "fontsize": 14})
    plt.xticks(fontsize=15)
    plt.yticks(rotation=0, fontsize=15)
    plt.xlabel('Bucket', size=18)
    plt.ylabel('Hour', fontsize=18)
    plt.title('Gender analysis per bucket and hour', fontsize=20)
    plt.show()
```

Проверьте действительно ли:

- посмотрев на долю мужчин в поступлениях средств (Income), можно сделать вывод, что количество поступлений средств мужчинам в целом больше, чем женщинам.
- самые низкие траты в 3 часа ночи осуществляются в более 80% случаев мужчинами.

Вариант №25

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Определите какой класс относится к мужчинам, а какой – к женщинам, и вычислите модуль разницы между их средними тратами (трата – отрицательное значение `amount`). Выведите ответ в виде вещественного числа, округлённого до двух знаков после запятой. Создайте новый столбец – `mcc_code+tr_type`, сложив значения из соответствующих столбцов.

Пояснения:

- Понять, какой класс к какому типу транзакций (мужские/женские) относится можно, если поизучать типичные для мужчин/женщин категории и сравнить средние/медианы расходов и/или доходов в них.
 - Если в результате для мужчин получились значения `[-1,-3,-5]`, а для женщин `[-1,-2,-3]`, то модуль разницы между средними арифметическими `-3` и `-2` будет равен `1`.
 - Округление не нужно производить отдельно по средним тратам женщин и мужчин, а только в самом конце, когда получите значение модуля разницы трат.
2. Из всех типов транзакций оставьте только траты (отрицательные суммы по столбцу `amount`). Выделите из поля `tr_datetime` относительный день `tr_day` (первое число до точного времени). Измените тип поля `tr_day` на `int`. Измените тип поля `tr_day` на `int`. Выберите из `transactions` все МСС коды, которые встретились в выборке более чем 50000 раз. Сгруппируйте отфильтрованный датафрейм по дню и МСС-коду, получая средние значения суммы `amount`. Отрисуйте зависимость средних сумм (может пригодится метод `unstack()`) по каждому из МСС-кодов по дням. Проверьте верно ли, что бакалейные магазины обладают максимальными средними тратами среди выбранных МСС-кодов.

Вариант №26

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). По всем типам транзакций рассчитайте максимальную сумму прихода на карту (из строго положительных сумм по столбцу `amount`) отдельно для мужчин и женщин (назовите ее `"max_income"`). Оставьте по 20 транзакций для мужчин и для женщин, наибольших среди всех транзакций по полученным значениям `"max_income"`. Выделите среди них те, которые встречаются одновременно у мужчин и у женщин.
2. Визуализируйте данные полученной таблицы с помощью круговой диаграммы.

Вариант №27

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Создайте новый столбец – `mcc_code+tr_type`, сконкатенировав значения из соответствующих столбцов (используйте метод `.astype(str)` и сложение серий). Оставьте только наблюдения с отрицательным значением `amount`. Посчитайте медиану трат по категориям получившегося столбца `mcc_code+tr_type`, в которых количество наблюдений ≥ 15 . Определите отношение максимальной медианы к минимальной. Выведите ответ в виде вещественного числа, округлённого до двух знаков после запятой.
2. По данным полученной таблицы (отфильтрованной по тратам и категориям с ≥ 15 наблюдениями) изобразите ящик с усами (`boxplot`) для распределения сумм по категориям, ограничившись первыми 10 категориями по количеству наблюдений. Проверьте, есть ли категория, у которой межквартильный размах (IQR) превышает 10000.

Вариант №28

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Выделите из поля `tr_datetime` час `tr_hour` (первые две цифры до ":") и день `tr_day` (всё до пробела). Оставьте только транзакции, совершённые в рабочие часы (с 8 до 20 включительно). Среди них оставьте только траты (отрицательный `amount`). Посчитайте для каждого часа среднюю трату по полу. Найдите час, в котором средняя трата мужчин превышает среднюю трату женщин в наибольшее число раз (отношение средних). Выведите этот час и значение отношения, округлённое до двух знаков.
2. Изобразите линейные графики зависимости средних трат от времени (по оси X – часы, по оси Y – средние траты) для мужчин и женщин на одном рисунке. Проверьте, верно ли, что в период с 12 до 14 часов средние траты почти совпадают (разница менее 5%).

Вариант №29

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Создайте новый столбец `mcc_description_tr_type`, сконкатенировав описание МСС и описание типа транзакции через пробел (используйте `apply`). Оставьте только транзакции с положительным `amount`. Посчитайте дисперсию сумм по каждой категории `mcc_description_tr_type`, в которых количество наблюдений ≥ 20 . Определите категорию с максимальной дисперсией и выведите её название и значение дисперсии (округлённое до целого).
2. Постройте гистограмму распределения сумм для найденной категории с максимальной дисперсией, наложив на неё график ядерной оценки плотности. Сделайте вывод о характере распределения (симметричное, скошенное и т.п.).

Вариант №30

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Оставьте только транзакции с отрицательным `amount` (траты). Разбейте все траты на 4 бакета равного объёма (`pd.qcut`) с метками ['A', 'B', 'C', 'D'] (A – самые большие по модулю, D – самые маленькие). Добавьте категорию 'Zero' для нулевых трат (если такие есть) – их отнесите к отдельной категории. Постройте сводную таблицу (`pivot_table`) с индексами – пол, столбцами – бакет, значениями – количество транзакций. Вычислите долю мужчин в каждом бакете (отношение числа мужчин к общему числу в бакете). Определите, в каком бакете доля мужчин максимальна, и выведите этот бакет и долю в процентах (округлённую до целого)
2. Визуализируйте полученную сводную таблицу в виде тепловой карты (`sns.heatmap`) с аннотацией. Проверьте, действительно ли в бакете с самыми крупными тратами (A) доля мужчин превышает 60%.

Вариант №31

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Оставьте только транзакции с положительным `amount` (приходы). Для каждого типа транзакции (`tr_type`) и каждого пола найдите максимальную сумму прихода. Затем для каждого типа транзакции вычислите разницу между максимальным приходом у мужчин и у женщин. Выведите тип транзакции, для которого эта разница максимальна (по модулю), и саму разницу (округлённую до целого). Если разница отрицательна, выведите модуль.
2. Постройте составную столбчатую диаграмму максимальных приходов по типам транзакций для мужчин и женщин. Проверьте, есть ли тип транзакции, где максимальный приход у женщин превышает мужской более чем в 2 раза.

Вариант №32

1. Считайте в переменные `tr_mcc_codes`, `tr_types`, `transactions` и `customers_gender_train` из одноимённых таблиц из папки `data`. В `transactions` считайте только первые 1000000 строк. Соедините `transactions` со всеми остальными таблицами (`tr_mcc_codes`, `tr_types`, `gender_train`). Причём с `customers_gender_train` необходимо смёрджиться с помощью `left join`, а с оставшимися датафреймами – через `inner` (в результате соединения датафреймов должно получиться 999584 строки). Из поля `tr_datetime` выделите час `tr_hour` (первые две цифры). Оставьте только траты (отрицательный `amount`). Сгруппируйте данные по часу и полу, вычислите среднюю трату и медиану траты. Для каждого часа вычислите отношение среднего к медиане. Найдите час, в котором это отношение максимально для мужчин, и час, в котором максимально для женщин. Выведите эти часы и соответствующие отношения, округлённые до двух знаков.
2. Постройте на одном рисунке с легендой по два графика зависимости средних и медиан трат от часа в разных окнах для мужчин и для женщин. Определите, в каких часах среднее значительно превышает медиану и совпадают ли эти часы у обоих полов.

Описание данных

Таблица `transactions.csv`

Описание

Таблица содержит историю транзакций клиентов банка за один год и три месяца.

Формат данных

```
customer_id,tr_datetime,mcc_code,tr_type,amount,term_id
111111,15 01:40:52,1111,1000,-5224,111111
111112,15 15:18:32,3333,2000,-100,11122233
...
```

Описание полей

- `customer_id` — идентификатор клиента;
- `tr_datetime` — день и время совершения транзакции (дни нумеруются с начала данных);
- `mcc_code` — мсс-код транзакции;
- `tr_type` — тип транзакции;
- `amount` — сумма транзакции в условных единицах со знаком; `+` — начисление средств клиенту (приходная транзакция), `-` — списание средств (расходная транзакция);
- `term_id` — идентификатор терминала;

Таблица `gender_train.csv`

Описание

Данная таблица содержит информацию по полу для части клиентов, для которых он известен. Для остальных клиентов пол неизвестен.

Формат данных

```
customer_id,gender
111111,0
111112,1
...
```

Описание полей

- `customer_id` — идентификатор клиента;
- `gender` — пол клиента;

Таблица `tr_mcc_codes.csv`

Описание

Данная таблица содержит описание мсс-кодов транзакций.

Формат данных

```
mcc_code;mcc_description
1000;словесное описание мсс-кода 1000
2000;словесное описание мсс-кода 2000
...
```

Описание полей

- `mcc_code` — мсс-код транзакции;
- `mcc_description` — описание мсс-кода транзакции.

Таблица `tr_types.csv`

Описание

Данная таблица содержит описание типов транзакций.

Формат данных

```
tr_type;tr_description
1000;словесное описание типа транзакции 1000
2000;словесное описание типа транзакции 2000
...
```

Описание полей

- `tr_type` — тип транзакции;
- `tr_description` — описание типа транзакции;

Ссылка для скачивания файлов:

<https://cloud.mail.ru/public/L2DU/UNuECvB1g>